

# 《数值计算方法》课程



## 最优化 (基于梯度的优化)

胡建芳

(研究方向：计算机视觉)

<http://sdcs.sysu.edu.cn/content/5143>

计算机学院

# 课程回顾

## ■ 数值微分，数值积分：

即 
$$I = \int_a^b f(x) dx \approx \sum_{k=0}^n A_k f(x_k) = I_n$$

$$(A_k = \int_a^b l_k(x) dx \quad k = 0, 1, \dots, n)$$

由上式确定系数的公式称为**插值型求积公式**。

则  $A_k = (b-a)C_k^{(n)}$ ，于是得求积公式

$$I_n = (b-a) \sum_{k=0}^n C_k^{(n)} f(x_k)$$

称为 **$n$  阶牛顿-柯特斯 (Newton-Cotes) 公式**， $C_k^{(n)}$  称为**柯特斯系数**。

节点等距的时候

# 课程回顾

常用的柯特斯系数表

$n$	$C_k^{(n)}$						
1	1/2	1/2					
2	1/6	4/6	1/6				
3	1/8	3/8	3/8	1/8			
4	7/90	32/90	12/90	32/90	7/90		
5	19/288	75/288	50/288	50/288	75/288	19/288	
6	41/840	216/840	27/840	272/840	27/840	216/840	41/840

还有其它内容，参见详细课程PPT.....


# 最优化（无约束条件）：

## ■ 基于梯度优化方法：

牛顿法

梯度下降法

随机梯度下降法



## ■ 梯度无关的优化方法

黄金分割搜索

持续抛物插值



**不考试，研究生学习的基础知识**

# 最优化（无约束条件）：

## 求解无约束最优化问题的基本思想



标准形式：

$$\min_{X \in E^n} f(X)$$

其中  $f: E^n \rightarrow E^1$

$$\max_{X \in E^n} f(X) = \min_{X \in E^n} [-f(X)]$$


求解的基本思想（以二元函数为例）






# 最优化（无约束条件）：


$$f(x_1, x_2) = -x_1^2 - x_2^2$$




$$f(x_1, x_2) = x_1^2 + x_2^2$$



$$f(x_1, x_2) = x_1^2 - x_2^2$$



# 最优化（无约束条件）：



# 最优化（无约束条件）：


搜索过程

$$\min f(x_1, x_2) = 100(x_2 - x_1^2)^2 + (1 - x_1)^2$$

最优解 (1 1)

初始点 (-1 1)

$x_1$	$x_2$	$f$
-1	1	4.00
-0.79	0.58	3.39
-0.53	0.23	2.60
-0.18	0.00	1.50
0.09	-0.03	0.98
0.37	0.11	0.47
0.59	0.33	0.20
0.80	0.63	0.05
0.95	0.90	0.003
0.99	0.99	1E-4
0.999	0.998	1E-5
0.9997	0.9998	1E-8




返回



# 基于梯度优化方法:

## ■ 牛顿法: 求方程: 一阶导数=0

- (1) 选定初始点  $X^0 \in E^n$ , 给定允许误差  $\varepsilon > 0$ , 令  $k=0$ ;
  - (2) 求  $\nabla f(X^k)$ ,  $(\nabla^2 f(X^k))^{-1}$ , 检验: 若  $\|\nabla f(X^k)\| < \varepsilon$ , 则  
停止迭代,  $X^* \approx X^k$ . 否则, 转向(3);
  - (3) 令  $S^k = -[\nabla^2 f(X^k)]^{-1} \nabla f(X^k)$  (牛顿方向);
  - (4)  $X^{k+1} = X^k + S^k$ ,  $k = k + 1$ , 转回(2).
- 

如果  $f$  是对称正定矩阵  $A$  的二次函数, 则用牛顿法经过一次迭代就可达到最优点, 如不是二次函数, 则牛顿法不能一步达到极值点, 但由于这种函数在极值点附近和二次函数很近似, 因此牛顿法的收敛速度还是很快的.

牛顿法的收敛速度虽然较快, 但要求 Hessian 矩阵要可逆, 要计算二阶导数和逆矩阵, 就加大了计算机计算量和存储量.

# 基于梯度优化方法：

## ■ 拟牛顿法：

为克服牛顿法的缺点，同时保持较快收敛速度的优点，利用第  $k$  步和第  $k+1$  步得到的  $X^k$ ， $X^{k+1}$ ， $\nabla f(X^k)$ ， $\nabla f(X^{k+1})$ ，构造一个正定矩阵  $G^{k+1}$  近似代替  $\nabla^2 f(X^k)$ ，或用  $H^{k+1}$  近似代替  $(\nabla^2 f(X^k))^{-1}$ ，将牛顿方向改为：

$$G^{k+1} S^{k+1} = -\nabla f(X^{k+1}), \quad S^{k+1} = -H^{k+1} \nabla f(X^{k+1})$$

从而得到下降方向.

<https://blog.csdn.net/songbinxu/article/details/79677948>

# 基于梯度优化方法：

## ■ 梯度下降法：

通常采用迭代法计算  $G^{k+1}$ ,  $H^{k+1}$ , 迭代公式为：

BFGS (Broyden-Fletcher-Goldfarb-Shanno) 公式

$$G^{k+1} = G^k + \frac{\Delta f^k (\Delta f^k)^T}{(\Delta f^k)^T \Delta x^k} - \frac{G^k \Delta x^k (\Delta x^k)^T G^k}{(\Delta x^k)^T G^k \Delta x^k}$$

$$H^{k+1} = H^k + \left( 1 + \frac{(\Delta f^k)^T H^k \Delta f^k}{(\Delta f^k)^T \Delta x^k} \right) \frac{\Delta x^k (\Delta x^k)^T}{(\Delta f^k)^T \Delta x^k} - \frac{\Delta x^k (\Delta f^k)^T H^k - H^k \Delta f^k (\Delta x^k)^T}{(\Delta f^k)^T \Delta x^k}$$

# 基于梯度优化方法:

## ■ 梯度下降法:

DFP (Davidon-Fletcher-Powell) 公式:

$$G^{k+1} = G^k + \left( 1 + \frac{(\Delta X^k)^T G^k \Delta X^k}{(\Delta X^k)^T \Delta f^k} \right) \frac{\Delta f^k (\Delta f^k)^T}{(\Delta f^k)^T \Delta X^k} - \frac{\Delta f^k (\Delta X^k)^T G^k - G^k \Delta X^k (\Delta f^k)^T}{(\Delta X^k)^T \Delta f^k}$$

$$H^{k+1} = H^k + \frac{\Delta X^k (\Delta X^k)^T}{(\Delta f^k)^T \Delta X^k} - \frac{H^k \Delta f^k (\Delta f^k)^T H^k}{(\Delta f^k)^T H^k \Delta f^k}$$

计算时可置  $H^1 = I$  (单位阵), 对于给出的  $X^1$  利用上面的公式进行递推. 这种方法称为**拟牛顿法**.



# 基于梯度优化方法：

## ■ 梯度下降法：

沿着负梯度方向，更新参数

Diagram illustrating the gradient descent update formula:

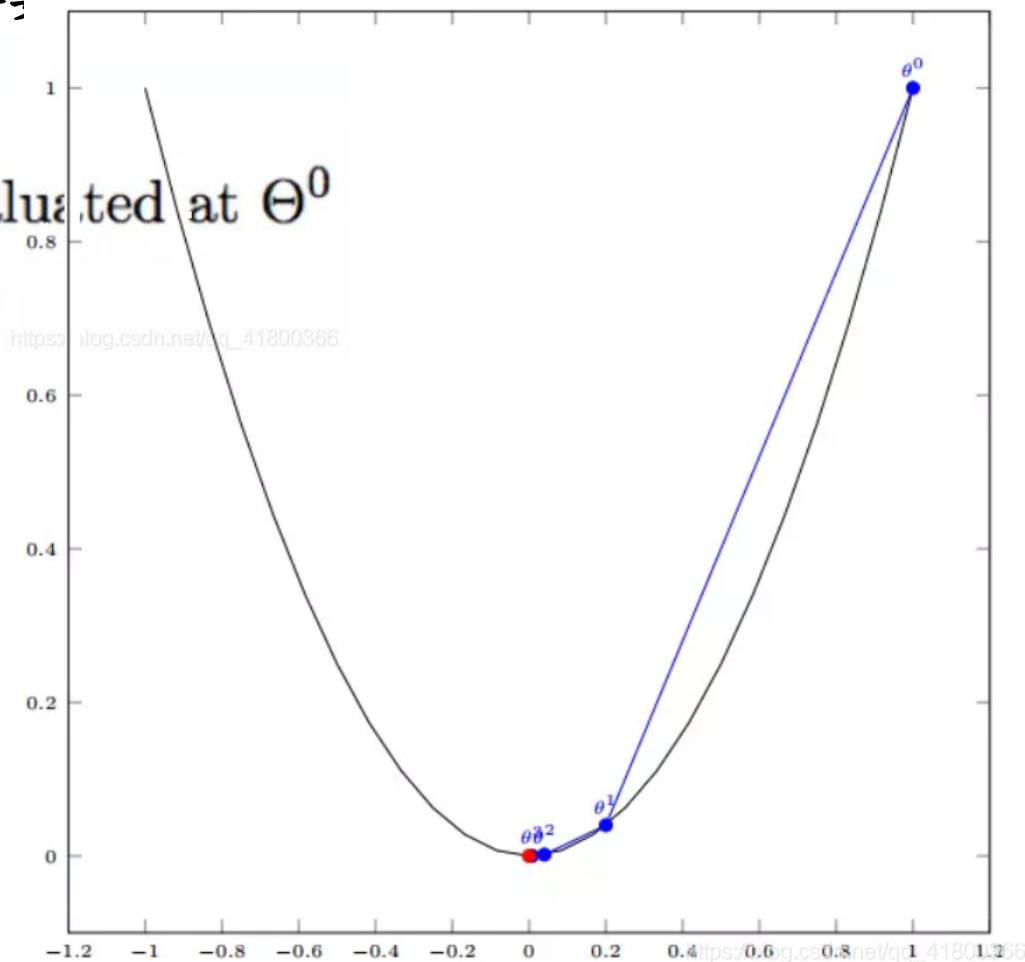
$$\theta^1 = \theta^0 - \alpha \nabla J(\theta)$$

Annotations:

- current position:  $\theta^0$
- opposite direction:  $-\nabla J(\theta)$
- small step:  $\alpha$
- direction of fastest increase:  $\nabla J(\theta)$
- next position:  $\theta^1$
- evaluated at  $\theta^0$

步长，调参  
核心之一  
可以搜索

形式简单，计算快  
收敛速度较慢



# 基于梯度优化方法：


## ■ 随机梯度下降法：

随机梯度下降算法每次从训练集中随机选择一部分样本来进行优化，即： $\theta = \theta - \eta \cdot \nabla \theta J(\theta; x_i; y_i)$

**波动较大：容易跳出比较差的局部最小值**

**形式简单，计算快**

**会收敛吗？**



# 基于梯度优化方法：

## ■ 动量 (momentum) :


保持之前运动的势能

$$\theta_{n+1} = \theta_n + v_{n+1}$$

$$v_{n+1} = \beta v_n - \alpha \nabla_{\theta} L(\theta_n)$$

1. 加速收敛
2. 提高精度(减少收敛过程中的振荡)

还有很多其它方法.....



# 梯度无关优化方法：

## ■ 黄金分割搜索：

逐步缩小搜索区间，直至极小值点存在的区间达到允许的误差范围

设一元函数 $f(a)$ 的起始搜索区间为 $[a, b]$ ,  $\alpha^*$  是函数的极小点。

在搜索区间 $[a, b]$ 内任取两点 $\alpha^{(1)}$ 、 $\alpha^{(2)}$ 。且 $a < \alpha^{(1)} < \alpha^{(2)} < b$ , 计算 $f(\alpha^{(1)})$ 、 $f(\alpha^{(2)})$ 。将 $f(\alpha^{(1)})$ 与 $f(\alpha^{(2)})$ 进行比较，可能出现三种情况：





# 梯度无关优化方法：

## ■ 黄金分割搜索：

逐步缩小搜索区间，直至极小值点存在的区间达到允许的误差范围

(1)  $f(\alpha^{(1)}) < f(\alpha^{(2)})$ . 在这种情况下，可以丢掉  $(\alpha^{(2)}, b]$  部分，而最小点必定在  $[a, \alpha^{(2)}]$  内。





# 梯度无关优化方法：

## ■ 黄金分割搜索：

逐步缩小搜索区间，直至极小值点存在的区间达到允许的误差范围

(2)  $f(\alpha^{(1)}) > f(\alpha^{(2)})$ . 在这种情况下，可以丢掉  $[a, \alpha^{(1)})$  部分，而最小点必定在  $[\alpha^{(1)}, b]$  内。




# 梯度无关优化方法:

## ■ 黄金分割搜索:

逐步缩小搜索区间，直至极小值点存在的区间达到允许的误差范围

(3)  $f(\alpha^{(1)}) = f(\alpha^{(2)})$ . 在这种情况下，可以丢掉  $[a, \alpha^{(1)})$  部分，也可以丢掉  $(\alpha^{(2)}, b]$  部分，而最小点必定在  $[\alpha^{(1)}, \alpha^{(2)}]$  内。因此这种情况可以并入上面的任意一种情况。




- (1)  $f(\alpha^{(1)}) \leq f(\alpha^{(2)})$ . 取区间  $[a, \alpha^{(2)}]$ ;
- (2)  $f(\alpha^{(1)}) > f(\alpha^{(2)})$ . 取区间  $[\alpha^{(1)}, b]$ 。

# 梯度无关优化方法:

## ■ 黄金分割搜索:

逐步缩小搜索区间，直至极小值点存在的区间达到允许的误差范围

1.  $\alpha^{(1)}, \alpha^{(2)}$  在  $[a, b]$  中位置对称
2. 每次缩短的区间缩短率不变，减少计算量。



$$\lambda = 0.618$$

$$\begin{aligned} \frac{L_2}{L_1} &= \frac{L_1}{L} \\ \frac{1-\lambda}{\lambda} &= \lambda \\ \lambda^2 + \lambda - 1 &= 0 \end{aligned}$$


⑬



# 梯度无关优化方法:

## ■ 黄金分割搜索:

逐步缩小搜索区间，直至极小值点存在的区间达到允许的误差范围



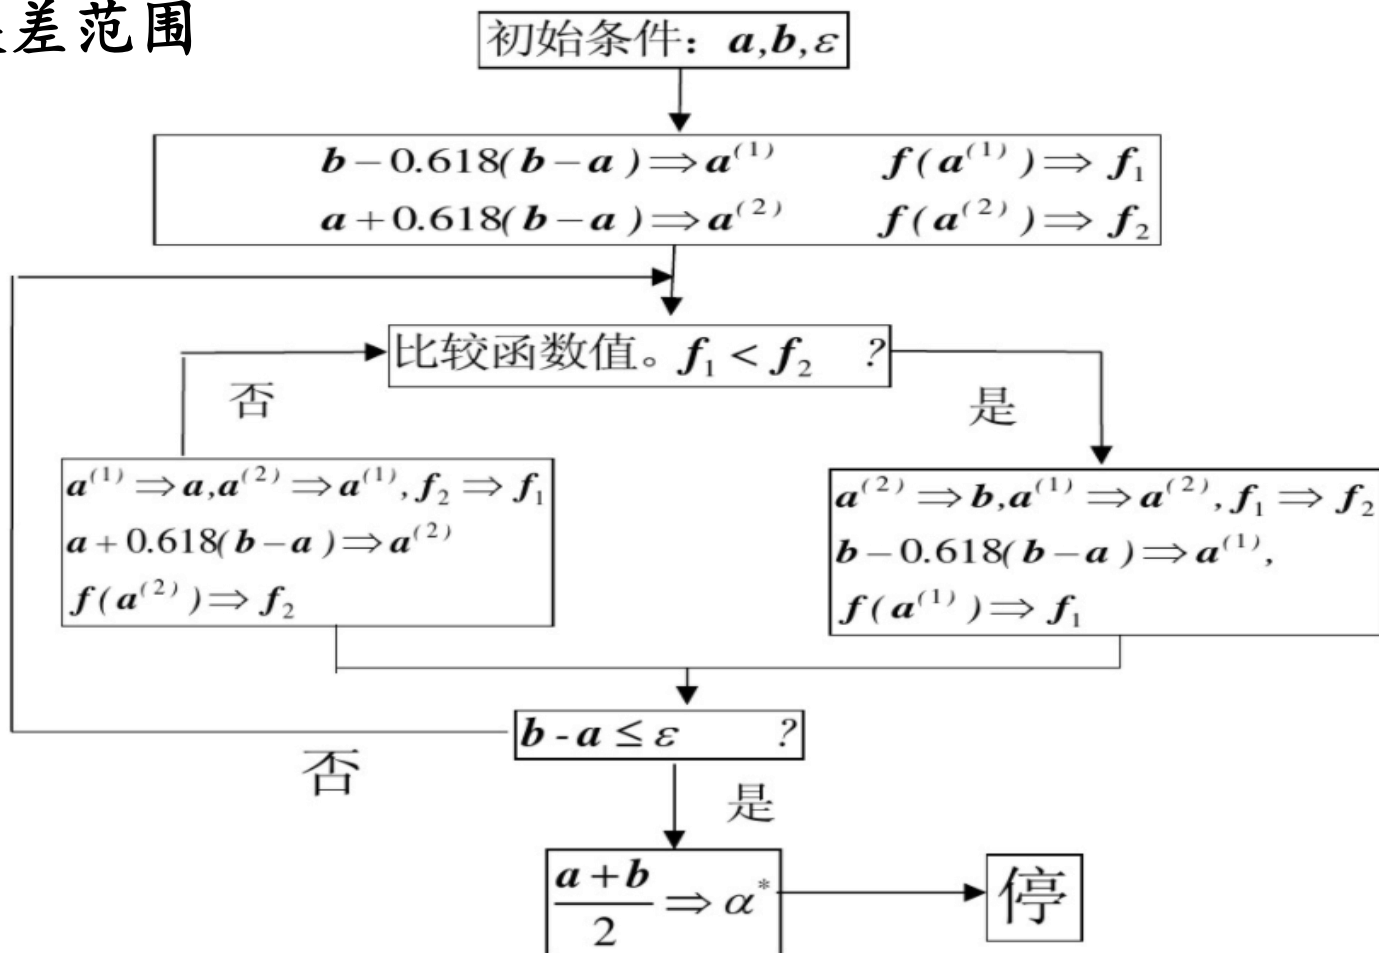
$$\lambda = 0.618$$

# 梯度无关优化方法:

## ■ 黄金分割搜索:

逐步缩小搜索区间，直至极小值点存在的区间达到允许的误差范围

黄金分割法计算框图



# 基于梯度优化方法：


---

## ■ 抛物插值法：

设函数在 $[a, b]$ 内呈现“大一小一大”单峰变化  
在 $[a, b]$ 上以低次（二次或三次）插值多项式 $P(x)$   
来逼近原目标函数，求得多项式的极值点，  
逐步缩短搜索区间。反复计算，直至给定精度。  
此法应用较广。

# 基于梯度优化方法：

## ■ 抛物插值法：



在 $[a, b]$ 中设定三点 $\alpha^{(1)}$ ,  $\alpha^{(2)}$ 和 $\alpha^{(3)}$

$$a \leq \alpha^{(1)} \leq \alpha^{(2)} \leq \alpha^{(3)} \leq b$$

对应有  $f_1, f_2, f_3$ , 且  $f_1 > f_2 < f_3$




# 基于梯度优化方法：

## ■ 抛物插值法：

构造二次多项式

$$P(x) = a_0 + a_1x + a_2x^2$$



由插值条件确定待定的 $a_i$  ( $i=0,1,2$ )

$$\left. \begin{aligned} P(\alpha^{(1)}) &= a_0 + a_1\alpha^{(1)} + a_2(\alpha^{(1)})^2 = f_1 \\ P(\alpha^{(2)}) &= a_0 + a_1\alpha^{(2)} + a_2(\alpha^{(2)})^2 = f_2 \\ P(\alpha^{(3)}) &= a_0 + a_1\alpha^{(3)} + a_2(\alpha^{(3)})^2 = f_3 \end{aligned} \right\} \cdots (1)$$

@13614068040

Baidu文库

# 基于梯度优化方法：

## ■ 抛物插值法：

求 $P(x)$ 极小点， $P(x) = a_1 + 2a_2x = 0$

$$\Rightarrow \alpha_P^* = -\frac{a_1}{2a_2}$$

$$\alpha_P^* = \frac{1}{2} \left( \alpha^{(1)} + \alpha^{(3)} - \frac{C_1}{C_2} \right)$$

$$\text{其中， } C_1 = \frac{f_3 - f_1}{\alpha^{(3)} - \alpha^{(1)}}$$

$$C_2 = \frac{(f_2 - f_1) / (\alpha^{(2)} - \alpha^{(1)}) - C_1}{\alpha^{(2)} - \alpha^{(3)}}$$


# 基于梯度优化方法：

## ■ 抛物插值法：

$$(1) \quad \alpha_p^* < \alpha^{(2)}, \quad f_p < f_2$$

$$\alpha^{(1)} = \alpha^{(1)}, \alpha^{(3)} = \alpha^{(2)}, \alpha^{(2)} = \alpha_p^*$$

$$f_1 = f_1, \quad f_3 = f_2, \quad f_2 = f_p$$




# 基于梯度优化方法：

## ■ 抛物插值法：

$$(2) \quad \alpha_P^* > \alpha^{(2)}, \quad f_P < f_2$$

$$\alpha^{(1)} = \alpha_P^*, \alpha^{(2)} = \alpha^{(2)}, \alpha^{(2)} = \alpha^{(3)}$$

$$f_1 = f_P, \quad f_2 = f_2, \quad f_3 = f_3$$




# 基于梯度优化方法：

## ■ 抛物插值法：

$$(3) \quad \alpha_P^* < \alpha^{(2)}, \quad f_P > f_2$$

$$\alpha^{(1)} = \alpha_P^*, \alpha^{(2)} = \alpha^{(2)}, \alpha^{(3)} = \alpha^{(3)}$$

$$f_1 = f_P, \quad f_3 = f_2, \quad f_3 = f_3$$






# 基于梯度优化方法：

## ■ 抛物插值法：

$$(4) \quad \alpha_P^* > \alpha^{(2)}, \quad f_P > f_2$$

$$\alpha^{(1)} = \alpha^{(1)}, \alpha^{(2)} = \alpha^{(2)}, \alpha^{(3)} = \alpha_P^*$$

$$f_1 = f_1, \quad f_2 = f_2, \quad f_3 = f_P$$



# 基于梯度优化方法：

## ■ 抛物插值法：

比较 $\alpha_p^*$ 与 $\alpha^{(2)}$ 两点， $f(x)$ 的大小；缩短搜索区间。

$$(1) \quad \alpha_p^* < \alpha^{(2)}, \quad f_p < f_2$$

$$\alpha^{(1)} \Rightarrow \alpha^{(1)}, \alpha^{(2)} \Rightarrow \alpha^{(3)}, \alpha_p^* \Rightarrow \alpha^{(2)}$$

$$(2) \quad \alpha_p^* > \alpha^{(2)}, \quad f_p < f_2$$

$$\alpha^{(2)} \Rightarrow \alpha^{(1)}, \alpha_p^* \Rightarrow \alpha^{(2)}, \alpha^{(3)} \Rightarrow \alpha^{(3)}$$

$$(3) \quad \alpha_p^* < \alpha^{(2)}, \quad f_p > f_2$$

$$\alpha_p^* \Rightarrow \alpha^{(1)}, \alpha^{(2)} \Rightarrow \alpha^{(2)}, \alpha^{(3)} \Rightarrow \alpha^{(3)}$$

$$(4) \quad \alpha_p^* > \alpha^{(2)}, \quad f_p > f_2$$

$$\alpha^{(1)} \Rightarrow \alpha^{(1)}, \alpha^{(2)} \Rightarrow \alpha^{(2)}, \alpha_p^* \Rightarrow \alpha^{(3)}$$

# 基于梯度优化方法：

## ■ 抛物插值法：

### 注意点

1) 三个试探点  $\alpha^{(1)} < \alpha^{(2)} < \alpha^{(3)}$   
且  $f_1 > f_2, f_2 < f_3$ ; "大-小-大"

2) 迭代中止条件

记  $\alpha^{(2)}$  与  $f_2$  是前一次迭代的插值函数极小点与极小值;

记  $\alpha^{(4)}$  与  $f_4$  是本次迭代的插值函数极小点与极小值。

$\varepsilon_1$ 、 $\varepsilon_2$  是给定的精度

若  $|\alpha^{(4)} - \alpha^{(2)}| < \varepsilon_1$  或  $|f_4 - f_2| < \varepsilon_2$

**THE END**