

# 《数值计算方法》课程



## 矩阵的特征值和奇异值

奇异值分解定理应用 (非常重要)

**胡建芳**

(研究方向: 计算机视觉)

<http://sdcs.sysu.edu.cn/content/5143>

计算机学院

# 课程回顾

## ■ 奇异值分解定理:

**定理** 设  $A \in R^{m \times n}$ , 秩  $(A) = r$ , 则存在  $m$  阶正交阵  $U$  和  $n$  阶正交阵  $V$ , 使得

$$U^T A V = \Sigma = \begin{bmatrix} \Sigma_r & 0 \\ 0 & 0 \end{bmatrix}$$

其中  $\Sigma_r = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r)$ , 且  $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$

称  $A = U \Sigma V^T = U \begin{bmatrix} \Sigma_r & 0 \\ 0 & 0 \end{bmatrix} V^T$  为矩阵  $A$  的奇异值分解,

$\Sigma = \begin{bmatrix} \Sigma_r & 0 \\ 0 & 0 \end{bmatrix}$  为矩阵  $A$  的奇异值矩阵。

$$\begin{matrix} \text{blue} & & \text{green} & & \text{blue} & & \text{orange} \\ A & = & U & \times & \Sigma & \times & V^T \\ m \times n & & m \times m & & m \times n & & n \times n \end{matrix} \longrightarrow \begin{matrix} \text{blue} & & \text{green} & & \text{blue} & & \text{orange} \\ A & = & U & \times & \Sigma & \times & V^T \\ m \times n & & m \times r & & r \times r & & r \times n \end{matrix}$$

# 奇异值分解应用

## ■ SVD的性质

性质 1 矩阵  $A = USV^T$  的秩是  $S$  中非零元素的个数.

性质 2 如果  $A$  是  $n \times n$  矩阵, 那么  $|\det(A)| = s_1 \cdots s_n$ .

性质 3 如果  $A$  是可逆  $m \times m$  逆阵, 那么  $A^{-1} = VS^{-1}U^T$ .

性质 4  $m \times n$  矩阵  $A$  可以写成秩 1 矩阵之和:

$$A = \sum_{i=1}^r s_i u_i v_i^T,$$

这里  $r$  是  $A$  的秩, 而  $u_i$  及  $v_i$  分别是  $U$  及  $V$  的第  $i$  列.

# 奇异值分解应用

## ■ SVD的性质

证

$$\begin{aligned} A &= USV^T = U \begin{bmatrix} s_1 & & \\ & \ddots & \\ & & s_r \end{bmatrix} V^T \\ &= U \left( \begin{bmatrix} s_1 \\ \vdots \\ 0 \end{bmatrix} + \begin{bmatrix} 0 \\ s_2 \\ \vdots \end{bmatrix} + \cdots + \begin{bmatrix} 0 \\ 0 \\ s_r \end{bmatrix} \right) V^T \\ &= s_1 \mathbf{u}_1 \mathbf{v}_1^T + s_2 \mathbf{u}_2 \mathbf{v}_2^T + \cdots + s_r \mathbf{u}_r \mathbf{v}_r^T. \end{aligned}$$

性质 4 是 SVD 的低秩近似性质. 通过保留 (12.31) 式的前面  $p$  项就提供了对秩  $p \leq r$  的  $A$  的最佳最小二乘近似.

# 奇异值分解应用

## ■ SVD的性质

例 12.8 求矩阵  $\begin{bmatrix} 0 & 1 \\ 1 & \frac{3}{2} \end{bmatrix}$  的最佳秩 1 近似.

写出 (12.31) 就得到

$$\begin{aligned} \begin{bmatrix} 0 & 1 \\ 1 & \frac{3}{2} \end{bmatrix} &= \begin{bmatrix} \frac{1}{\sqrt{5}} & -\frac{2}{\sqrt{5}} \\ \frac{2}{\sqrt{5}} & \frac{1}{\sqrt{5}} \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 0 & \frac{1}{2} \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{5}} & \frac{2}{\sqrt{5}} \\ \frac{2}{\sqrt{5}} & -\frac{1}{\sqrt{5}} \end{bmatrix} \\ &= \begin{bmatrix} \frac{1}{\sqrt{5}} & -\frac{2}{\sqrt{5}} \\ \frac{2}{\sqrt{5}} & \frac{1}{\sqrt{5}} \end{bmatrix} \left( \begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix} + \begin{bmatrix} 0 & 0 \\ 0 & \frac{1}{2} \end{bmatrix} \right) \begin{bmatrix} \frac{1}{\sqrt{5}} & \frac{2}{\sqrt{5}} \\ \frac{2}{\sqrt{5}} & -\frac{1}{\sqrt{5}} \end{bmatrix} \\ &= 2 \begin{bmatrix} \frac{1}{\sqrt{5}} \\ \frac{2}{\sqrt{5}} \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{5}} & \frac{2}{\sqrt{5}} \end{bmatrix} + \frac{1}{2} \begin{bmatrix} -\frac{2}{\sqrt{5}} \\ \frac{1}{\sqrt{5}} \end{bmatrix} \begin{bmatrix} \frac{2}{\sqrt{5}} & -\frac{1}{\sqrt{5}} \end{bmatrix} \\ &= \begin{bmatrix} \frac{2}{5} & \frac{4}{5} \\ \frac{4}{5} & \frac{8}{5} \end{bmatrix} + \begin{bmatrix} -\frac{2}{5} & \frac{1}{5} \\ \frac{1}{5} & -\frac{1}{10} \end{bmatrix}. \end{aligned}$$

# 奇异值分解应用

## ■ 数据降维

SVD 给出了一个直接了当的方法执行降维. 把数据向量考虑为  $m \times n$  矩阵  $A = (a_1 | \cdots | a_n)$  的列, 并且计算奇异值分解  $A = USV^T$ , 设  $e_j$  表示第  $j$  个基本基向量 (即第  $j$  个分量是 1, 其他分量全为 0). 于是  $Ae_j = a_j$ . 利用性质 4 的秩  $p$  近似

$$A \approx A_p = \sum_{i=1}^p s_i u_i v_i^T,$$

我们可以通过

$$a_j = Ae_j \approx A_p e_j \tag{13.33}$$

把  $a_j$  投影到由  $U$  的列  $u_1, \cdots, u_p$  所张成的  $p$  维空间中, 因为把一个矩阵乘以  $e_j$  恰好是把它的第  $j$  列挑选出来, 我们能更有效地叙述求解如下:

# 奇异值分解应用

## ■ 数据降维

例 12.9 求拟合数据向量  $[3, 2]$ ,  $[2, 4]$ ,  $[-2, -1]$ ,  $[-3, -5]$  的最佳一维子空间.




图 12-4 用 SVD 降维. (a) 4 个数据向量被投影到最佳一维子空间.  
(b) 虚线表示最佳子空间. 箭头表明到子空间的正交投影

# 奇异值分解应用

## ■ 数据降维

例 12.9 求拟合数据向量  $[3, 2], [2, 4], [-2, -1], [-3, -5]$  的最佳一维子空间.

$$A = \begin{bmatrix} 3 & 2 & -2 & -3 \\ 2 & 4 & -1 & -5 \end{bmatrix}$$

$$\begin{bmatrix} 0.5886 & -0.8084 \\ 0.8084 & 0.5886 \end{bmatrix} \begin{bmatrix} 8.2809 & 0 & 0 & 0 \\ 0 & 1.8512 & 0 & 0 \end{bmatrix} \begin{bmatrix} 0.4085 & 0.5327 & -0.2398 & -0.7014 \\ -0.6741 & 0.3985 & 0.5554 & -0.2798 \\ 0.5743 & -0.1892 & 0.7924 & -0.0801 \\ 0.2212 & 0.7223 & 0.0780 & 0.6507 \end{bmatrix}.$$

$$S_1 = \begin{bmatrix} 8.2809 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$

$$A_1 = \begin{bmatrix} 1.9912 & 2.5964 & -1.1689 & -3.4188 \\ 2.7346 & 3.5657 & -1.6052 & -4.695 \end{bmatrix}$$



# 奇异值分解应用

## ■ 数据压缩

依旧从奇异值分解的表达式入手,  $A = U\Sigma V^T$ , 我们展开成完整的矩阵形式:

$$A = \begin{bmatrix} u_1 & u_2 & \dots & u_m \end{bmatrix} \begin{bmatrix} \sigma_1 & & & \\ & \sigma_2 & & \\ & & \dots & \\ & & & \sigma_r \end{bmatrix} \begin{bmatrix} v_1^T \\ v_2^T \\ \dots \\ v_n^T \end{bmatrix}, \text{ 这里}$$

$$r \leq n < m .$$

这里展开就得到了:

$$A = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T + \sigma_3 u_3 v_3^T + \dots + \sigma_r u_r v_r^T$$


# 奇异值分解应用

## ■ 数据压缩

行近似:


$$A \Rightarrow \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T + \sigma_3 u_3 v_3^T + \dots + \sigma_k u_k v_k^T .$$

原理示意图如图1所示:



# 奇异值分解应用

- **数据压缩** <http://www.johnmyleswhite.com/notebook/2009/12/17/image-compression-with-the-svd-in-r/>



# 奇异值分解应用

---

## ■ 数据压缩

压缩是因为样本的相关性较大，冗余成分较多  
对于多张图像，怎么去压缩？

# 奇异值分解应用

---

- PCA 主成分分析  
自主学习。

# 奇异值分解大作业

## ■ 主成分分析 (PCA) 实验

### 一)：人脸数据库

每个人拍摄10张照片（**关掉美颜**），不同照片拍摄角度轻微不同，拍摄角度可以参考以下照片。

### 二)：实验

选择上述一个数据集进行主成分分析 (PCA) 实验。PCA算法

自行学习。实验结果包含如下内容：

1. 用PCA降维（压缩）后，所得到的人脸图片与原始人脸图片对比。
2. 结合最近邻分类器，测试PCA降维算法的识别率。

**2-3人一小组，  
1个月内完成。**



<http://blog.csdn.net/on2way>

---

**THE END**